第2次作业

谢宝进

目录

```
1 问题 1: BigBangTheory
```

#> [1] 15.04286

1

```
# 加载数据包
library(tidyverse)
library(dplyr)
library(readxl)
```

1 问题 1: BigBangTheory

```
BigBangTheory <- read_csv("assignment 2/data/BigBangTheory.csv")

# View(BigBangTheory)

## a 最少观看人数和最多观看人数
min(BigBangTheory$ 'Viewers (millions)')

#> [1] 13.3

max(BigBangTheory$ 'Viewers (millions)')

#> [1] 16.5

##b 观看人数的均值、中位数和众数
mean(BigBangTheory$ 'Viewers (millions)')
```

```
median(BigBangTheory$ 'Viewers (millions)')

#> [1] 15

as.numeric(names(sort(table(BigBangTheory$ 'Viewers (millions)'), decreasing = TRUE)[1]))

#> [1] 13.6

##c 第一分位数和第三分位数
quantile(BigBangTheory$ 'Viewers (millions)', probs =0.25)

#> 25%


#> 14.1

quantile(BigBangTheory$ 'Viewers (millions)', probs =0.75)

#> 75%

#> 16

##d 讨论 2011-2012 季收视率上升还是下降
ggplot(data=BigBangTheory,aes(x=`Air Date',y=`Viewers (millions)'))+geom_point()+geom_line()
```



#问题 2: NBAPlayerPts

```
## 加載数据
data_1 <- read_csv("assignment 2/data/NBAPlayerPts.csv")

##a 统计频率分布
breaks <- seq(10, 30, by = 2)
frequency <-table(cut(data_1$PPG, breaks = breaks))
print(frequency)

#>
#> (10,12] (12,14] (14,16] (16,18] (18,20] (20,22] (22,24] (24,26] (26,28] (28,30]
#> 1 4 6 20 8 4 2 0 3 2

##b 相对频率分布
relative_frequency <-prop.table(frequency)
print(relative_frequency)
```


```
#> (10,12] (12,14] (14,16] (16,18] (18,20] (20,22] (22,24] (24,26] (26,28] (28,30] #> 0.02 0.08 0.12 0.40 0.16 0.08 0.04 0.00 0.06 0.04
```

```
##c 累积百分比分布
cumulative_percent <- cumsum(relative_frequency)
print(cumulative_percent)
```

```
#> (10,12] (12,14] (14,16] (16,18] (18,20] (20,22] (22,24] (24,26] (26,28] (28,30] 
#> 0.02  0.10  0.22  0.62  0.78  0.86  0.90  0.90  0.96  1.00
```

```
##d 直方图
hist(data_1$PPG, xlab = "PPG", col = "skyblue", border = "white")
```

Histogram of data_1\$PPG



```
##e 偏态分析
skewness <- sum((data_1$PPG - mean(data_1$PPG))^3) / (length(data_1$PPG) * sd(data_1$PPG)^3)
```

```
# f. 每场比赛得分至少 20 分的球员百分比
percentage_20plus <- mean(data_1$PPG >= 20)
print(percentage_20plus)
#> [1] 0.22
#问题 3:调查样本及概率问题
##a 样本大小?
# 已知值
std_error <- 20
std_dev <- 500
n <- (std_dev / std_error)^2</pre>
print(n)
#> [1] 625
##b ±25 内的概率
z <- 25 / std_error
prob <- pnorm(z) - pnorm(-z)</pre>
print(prob)
#> [1] 0.7887005
#问题 4: 青年杂志
# 加载数据
data_2 <- read_csv("assignment 2/data/Professional.csv")</pre>
view(data_2)
##a 描述性统计
summary(data_2)
```

#问题 5: Quality Associate

```
#> 3rd Qu.:33.00
#> Max. :42.00
#> Value of Investments ($) Number of Transactions Broadband Access?
#> Min. :
                          Min. : 0.000
               0
                                                Length:410
#> 1st Qu.: 18300
                          1st Qu.: 4.000
                                                Class : character
#> Median : 24800
                          Median : 6.000
                                                Mode :character
#> Mean : 28538
                          Mean : 5.973
#> 3rd Qu.: 34275
                          3rd Qu.: 7.000
#> Max. :133400
                          Max.
                                :21.000
#> Household Income ($) Have Children?
                                        ...9
                                                         ...10
                                        Mode:logical Length:410
#> Min. : 16200
                       Length:410
#> 1st Qu.: 51625
                      Class:character NA's:410
                                                      Class : character
#> Median : 66050
                     Mode : character
                                                      Mode :character
#> Mean : 74460
#> 3rd Qu.: 88775
#> Max.
         :322500
#> ...11
                 ...12
                              ...13
                                             . . . 14
#> Mode:logical Mode:logical
                                             Mode:logical
#> NA's:410
                NA's:410
                               NA's:410
                                             NA's:410
#>
#>
#>
#>
##b 年龄和收入在 95% 执行水平的置信区间
t.test(data_2$Age,conf.level = 0.95)$conf.int # 计算年龄的区间
#> [1] 29.72153 30.50286
#> attr(,"conf.level")
#> [1] 0.95
t.test(data_2* Household Income ($) , conf.level = 0.95) $conf.int # 计算收入的区间
#> [1] 71079.26 77839.77
#> attr(,"conf.level")
#> [1] 0.95
```

```
##a 对每个样本进行假设检验,并确定应采取哪些措施。
quality <- read_csv("assignment 2/data/Quality.csv") # 导入数据
alpha <- 0.01 # 定义显著性水平
sample_means <- apply(quality, 1, mean) # 计算样本均值
sample_sds <- apply(quality, 1, sd) # 计算标准差
# 总体标准差
sigma <- 0.21
n <- 30
# 进行假设检验
t_tests <- sapply(1:nrow(quality), function(i) {</pre>
  t_stat <- (sample_means[i] - 12) / (sigma / sqrt(n))
 p_value <- 2 * pt(abs(t_stat), df = n - 1, lower.tail = FALSE)</pre>
 list(t_stat = t_stat, p_value = p_value)
})
t tests # 输出结果
          [,1]
                      [,2]
                                 [,3]
                                             [,4]
                                                        [,5]
                                                                 [,6]
#>
#> t_stat -5.868456
                     -8.541864
                                -7.107352
                                             -1.956152 0.7824608 -5.607636
```

```
#> p_value 2.28638e-06 2.07292e-09 8.055516e-08 0.06014044 0.4402866 4.696334e-06
           [,7]
#>
                       [,8]
                                  [,9]
                                              [,10]
                                                         [,11]
                                                                     [,12]
#> t_stat -4.368739
                       -2.477793 3.260253
                                             -3.455869
                                                         3.651484
                                                                     -1.564922
#> p_value 0.0001458471 0.0192882 0.002843649 0.001711572 0.001021295 0.1284495
          [,13]
                      [,14]
                                [,15]
                                             [,16]
                                                        [,17]
                                                                    [,18]
#> t_stat 2.347382
                     -0.4564355 4.49915
                                             1.890947
                                                        -0.5216405 -5.738046
#> p_value 0.02594231 0.6514771 0.0001017738 0.06865983 0.6058821 3.275305e-06
#>
           [,19]
                      [,20]
                                  [,21]
                                             [,22]
                                                        [,23]
                                                                   [,24]
#> t_stat 2.673408
                     -3.129843
                                -0.1956152 2.412587
                                                       1.825742
                                                                  8.867889
#> p_value 0.01220001 0.003967029 0.8462756 0.02239019 0.07820332 9.360888e-10
#>
           [,25]
                     [,26]
                              [,27]
                                          [,28]
                                                    [,29]
                                                                 [,30]
#> t_stat 1.369306 0.9128709 1.956152 -2.412587 5.085995
                                                                 3.586279
#> p_value 0.1814154 0.3688376 0.06014044 0.02239019 1.997275e-05 0.001214172
```

##b 计算 4 个样本的标准差,并判断假设是否合理 sample_sds [1] 0.22575798 0.27170756 0.23556669 0.18912077 0.11401754 0.19330460 #> [7] 0.18191115 0.20566964 0.19908122 0.14930394 0.04082483 0.24589971 #> [13] 0.14719601 0.33129795 0.21515498 0.18839232 0.11401754 0.03366502 #> [19] 0.19050372 0.16268579 0.29136175 0.13524669 0.15165751 0.10614456 #> [25] 0.22156639 0.09678154 0.15286159 0.05057997 0.21763884 0.14453950 # 判断假设是否合理 mean(sample_sds) # 计算样本标准差的平均值 **#>** [1] 0.1734486 ##c 计算样本的界限,并判断新样本是否在界限内,如果不在则需采取纠正措施。 # 计算控制限 upper_limit <- 12 + 3 * (sigma / sqrt(n))</pre> lower_limit <- 12 - 3 * (sigma / sqrt(n))</pre> #输出界限 c(upper_limit, lower_limit) #> [1] 12.11502 11.88498 ##d. 讨论将显著性水平提高到更大值的影响。如果将显著性水平提高, 哪种错误可能会增加? # 如果显著性水平增加,第一类错误(错误地拒绝正确的零假设)的风险会增加。 # 这意味着可能会更频繁地采取不必要的纠正措施, 导致成本增加和生产效率降低。 # 问题 6: 入住率 occupancy <- read_csv("assignment 2/data/Occupancy.csv") # 数据导入 ##a 估算 2007 年 3 月第一周和 2008 年 3 月第一周的单元出租比例 # 将原始数据转化为 0/1, 区分是否出租 occupancy\$`Mar-07` <- ifelse(occupancy\$`Mar-07`=="Yes",1,0)</pre>

```
occupancy$`Mar-08` <- ifelse(occupancy$`Mar-08`=="Yes",1,0)
# 计算样本大小
n <- nrow(occupancy)</pre>
# 计算 2007 年 3 月第一周出租单位的比例
prop_2007 <- mean(occupancy$`Mar-07`)</pre>
# 计算 2008 年 3 月第一周出租单位的比例
prop_2008 <- mean(occupancy$`Mar-08`)</pre>
# 打印结果
cat("Proportion of units rented in Mar.07:", prop_2007, "\n")
#> Proportion of units rented in Mar.07: 0.35
cat("Proportion of units rented in Mar.08:", prop_2008, "\n")
#> Proportion of units rented in Mar.08: NA
##b 为比例之差提供一个 95% 的置信区间
se_diff <- sqrt((prop_2007 * (1 - prop_2007) / n) + (prop_2008 * (1 - prop_2008) / n)) # 计算比例差
ci_diff <- c(prop_2008 - prop_2007 - 1.96 * se_diff, prop_2008 - prop_2007 + 1.96 * se_diff) # #
# 输出结果
cat("95% Confidence Interval for the difference in proportions:", ci_diff, "\n")
#> 95% Confidence Interval for the difference in proportions: NA NA
##c 根据发现, 2008 年 3 月的租赁率是否会相比前一年同期有所上涨?
 cat(" 有明显证据证明 08 年 3 月租金会同比上升.\n")
```


- #> 有明显证据证明08年3月租金会同比上升.
- #问题 7: 空军训练方案

```
Training <- read_csv("assignment 2/data/Training.csv") # 导入数据
##a use appropriate descriptive statistics to summarize the training time data for each method.
#what similarities or differences do you observe from the sample data?
# 描述性统计
summary_current <- summary(Training$Current)</pre>
summary_proposed <- summary(Training$Proposed)</pre>
# 打印结果
cat(" 当前方法的描述性统计:\n")
#> 当前方法的描述性统计:
print(summary_current)
#>
      Min. 1st Qu. Median
                            Mean 3rd Qu.
                                             Max.
#>
     65.00
           72.00
                   76.00
                            75.07
                                    78.00
                                            84.00
cat(" 提议方法的描述性统计:\n")
#> 提议方法的描述性统计:
print(summary_proposed)
#>
      Min. 1st Qu. Median
                             Mean 3rd Qu.
                                             Max.
     69.00
            74.00
                    76.00
                            75.43
                                    77.00
                                            82.00
#>
##b Comment on any difference between the population means for the two methods. Discuss
# your findings.
# t 检验
t_test_result <- t.test(Training Current, Training Proposed, var.equal = TRUE)
print(t_test_result)
#>
#> Two Sample t-test
#>
#> data: Training$Current and Training$Proposed
\#> t = -0.60268, df = 120, p-value = 0.5479
#> alternative hypothesis: true difference in means is not equal to 0
#> 95 percent confidence interval:
```

```
#> -1.5454793 0.8241679
#> sample estimates:
#> mean of x mean of y
#> 75.06557 75.42623
#3.c. compute the standard deviation and variance for each training method. conduct a hypothesis
#test about the equality of population variances for the two training methods. Discuss your
#findings
# 计算标准差和方差
sd_current <- sd(Training$Current)</pre>
var_current <- var(Training$Current)</pre>
sd_proposed <- sd(Training$Proposed)</pre>
var_proposed <- var(Training$Proposed)</pre>
# 方差齐性检验
var_test_result <- var.test(Training$Current, Training$Proposed)</pre>
print(var_test_result)
#>
#> F test to compare two variances
#>
#> data: Training$Current and Training$Proposed
\#F = 2.4773, num df = 60, denom df = 60, p-value = 0.000578
#> alternative hypothesis: true ratio of variances is not equal to 1
#> 95 percent confidence interval:
#> 1.486267 4.129135
#> sample estimates:
#> ratio of variances
            2.477296
#>
#4. what conclusion can you reach about any differences between the two methods? what is your
#recommendation? explain
# 结论: 两种方法的均值没有显著差异,但方差存在显著差异,表明提议方法在训练时间上更加一致。
#5.can you suggest other data or testing that might be desirable before making a final decision
#on the training program to be used in the future?
# 鉴于两种方法的均值相似,但提议方法的方差较小,可能更值得考虑采用提议方法,因为它可能提供更一致的训练体验
```

问题 8: 凯美瑞

```
# 加载数据
camry <- read_csv("assignment 2/data/Camry.csv")
##a 以汽车里程数为横轴,价格为纵轴绘制散点图
# 绘制散点图
ggplot(camry, aes(x = camry$`Miles (1000s)`, y = camry$`Price ($1000s)`)) +
geom_point() + #添加散点图
geom_smooth() #添加默认的平滑拟合线
```



```
##b 在部分(a) 中绘制的散点图显示了这两个变量之间有什么关系?
# 从散点图中,我们可以看出里程和价格之间存在负相关关系。随着里程的增加,价格呈下降趋势

##c 根据里程数(以千为单位)来开发一个估计的回归方程,用于预测价格(以千美元为单位)。
# 估计回归方程
model <- lm(camry$`Price ($1000s)` ~ camry$`Miles (1000s)`, data=camry)
summary(model)
```

#>

#> Call:

#> (Intercept)

```
#> lm(formula = camry$`Price ($1000s)` ~ camry$`Miles (1000s)`,
#>
      data = camry)
#>
#> Residuals:
               1Q
#>
      Min
                 Median
                              3Q
                                     Max
#> -2.32408 -1.34194 0.05055 1.12898 2.52687
#> Coefficients:
#>
                     Estimate Std. Error t value Pr(>|t|)
#> (Intercept)
                     #> camry$`Miles (1000s)` -0.05877
                               0.01319 -4.455 0.000348 ***
#> Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
#>
#> Residual standard error: 1.541 on 17 degrees of freedom
#> Multiple R-squared: 0.5387, Adjusted R-squared: 0.5115
#> F-statistic: 19.85 on 1 and 17 DF, p-value: 0.0003475
##d 在 0.05 的显著性水平下检验是否存在显著关系。
# 答: 从回归方程的估计结果中, 我们可以看到 Miles 的 p 值为 0.000348, 远小于 0.05, 因此在 0.05 的显著性力
##e 估计的回归方程是否提供了良好的拟合?请解释。
# 答: R 平方值 0.5387, 调整后的 R 平方值为 0.5115, 这表明回归方程对数据的拟合度较好, 可以解释 51.15% 的
##f 对估计的回归方程的斜率进行解释
# 答:斜率-0.05877 表示每增加 1000 英里的里程,价格平均下降 0.05877 千美元。
##g 假设你正在考虑购买一辆已经行驶了 60,000 英里的二手 2007 款凯美瑞。使用在部分(c)中开发的估计回归方程
# 获取模型的系数
coefficients <- coef(model)</pre>
intercept <- coefficients[1]</pre>
slope <- coefficients[2]</pre>
# 计算预测价格
predicted_price <- intercept + slope * 60</pre>
predicted_price
```

#> 12.94332

```
predicted_price_2 <- round(predicted_price, 2)
paste(" 预测价格 $",predicted_price_2," 千元")
```


#> [1] "预测价格\$ 12.94 千元"

#问题 9: 流失率

```
data <- read_excel("assignment 2/data/WE.xlsx") # 导入数据
##a 通过可视化探索流失客户与□流失客户的□为特点(或特点对□),你能发现流失与□流失客
# 户□为在哪些指标有可能存在显著不同?
data_long <- data %>%
    pivot_longer(cols = -流失, names_to = " 指标", values_to = " 值") %>%
    mutate(流失 = factor(流失, labels = c(" 非流失", " 流失")))

ggplot(data_long, aes(x = 流失, y = 值, fill = 流失)) +
    geom_boxplot() +
    facet_wrap(~指标, scales = "free") +
    labs(title = " 流失与非流失客户行为特点比较", x = " 客户状态", y = " 指标值")
```

流失与非流失客户行为特点比较



```
##b 通过均值□较的□式验证上述不同是否显著。
# 计算均值并进行 t 检验

t_tests <- data %>%

pivot_longer(cols = -流失, names_to = " 指标", values_to = " 值") %>%

group_by(指标) %>%

do({

    t_test <- t.test(.$值 [.$流失 == 0], .$值 [.$流失 == 1])

    data.frame(指标 = unique(.$指标), 非流失_mean = mean(.$值 [.$流失 == 0], na.rm = TRUE), 流失_mea
}) %>%

ungroup()

# 显示 t 检验结果
t_tests
```

#> # A tibble: 12 x 4

#>	2	客户ID	3219.	2330.	5.98e-20
#>	3	客户使用期限	18.8	20.4	3.06e- 3
#>	4	客户幸福指数相比上月变化	5.53	-3.74	1.57e- 8
#>	5	客户支持相比上月的变化	-0.00930	0.0372	5.28e- 1
#>	6	当月客户幸福指数	88.6	63.3	2.10e-13
#>	7	当月客户支持	0.724	0.372	6.28e- 8
#>	8	当月服务优先级	0.830	0.500	4.38e- 7
#>	9	当月登录次数	16.1	8.06	4.04e- 4
#>	10	服务优先级相比上月的变化	0.0327	-0.0167	5.22e- 1
#>	11	访问次数相比上月的增加	107.	-95.8	5.63e- 2
#>	12	访问间隔变化	3.51	8.49	5.22e- 5

print(t_tests)

#> # A tibble: 12 x 4

#>		指标	非流失_mean	流失_mean	p_value
#>		<chr></chr>	<dbl></dbl>	<dbl></dbl>	<dbl></dbl>
#>	1	博客数相比上月的变化	0.171	-0.102	1.16e- 2
#>	2	客户ID	3219.	2330.	5.98e-20
#>	3	客户使用期限	18.8	20.4	3.06e- 3
#>	4	客户幸福指数相比上月变化	5.53	-3.74	1.57e- 8
#>	5	客户支持相比上月的变化	-0.00930	0.0372	5.28e- 1
#>	6	当月客户幸福指数	88.6	63.3	2.10e-13
#>	7	当月客户支持	0.724	0.372	6.28e- 8
#>	8	当月服务优先级	0.830	0.500	4.38e- 7
#>	9	当月登录次数	16.1	8.06	4.04e- 4
#>	10	服务优先级相比上月的变化	0.0327	-0.0167	5.22e- 1
#>	11	访问次数相比上月的增加	107.	-95.8	5.63e- 2
#>	12	访问间隔变化	3.51	8.49	5.22e- 5

##c 以"流失"为因变量,其他你认为重要的变量为□变量(提示: a、b 两步的发现),建□回归□ # 程对是否流失进□预测。

model <- glm(流失 ~ 客户 ID + 当月客户幸福指数 + 客户幸福指数相比上月变化 + 当月客户支持 + 当月服务优势

显示模型摘要

summary(model)

#>

#> Call:

```
#> glm(formula = 流失 ~ 客户ID + 当月客户幸福指数 +
      客户幸福指数相比上月变化 + 当月客户支持 +
      当月服务优先级, family = binomial, data = data)
#>
#>
#> Coefficients:
                          Estimate Std. Error z value Pr(>|z|)
#>
#> (Intercept)
                        -1.211e+00 1.359e-01 -8.912 <2e-16 ***
#> 客户ID
                        -3.539e-04 3.366e-05 -10.516 <2e-16 ***
#> 当月客户幸福指数
                        -9.305e-03 1.125e-03 -8.267 <2e-16 ***
#> 客户幸福指数相比上月变化 -4.194e-03 2.285e-03 -1.835 0.0665 .
#> 当月客户支持
                        6.730e-03 6.822e-02 0.099 0.9214
#> 当月服务优先级
                      -3.799e-02 7.307e-02 -0.520 0.6031
#> ---
#> Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
#>
#> (Dispersion parameter for binomial family taken to be 1)
#>
      Null deviance: 2553.1 on 6346 degrees of freedom
#>
#> Residual deviance: 2371.3 on 6341 degrees of freedom
#> AIC: 2383.3
#>
#> Number of Fisher Scoring iterations: 6
##d 根据上□步预测的结果,对尚未流失(流失 =0)的客户进□流失可能性排序,并给出流失可能
 # 性最□的前 100 名□户 ID 列表。
# 筛选出尚未流失的客户
data_non_churn <- data[data$流失 == 0,]
# 预测尚未流失的客户流失可能性
predictions <- predict(model, newdata = data_non_churn, type = "response")</pre>
# 将预测结果添加到筛选后的数据框中
data_non_churn$predictions <- predictions</pre>
# 对尚未流失的客户进行排序
data_non_churn_sorted <- data_non_churn[order(-data_non_churn$predictions), ]
# 显示流失可能性最大的前 100 名用户 ID
```

```
top100_users <- head(data_non_churn_sorted$客户 ID, 100)
print(top100_users)
```

```
#>
    [1] 109
              76
                  57 318 305 240 183
                                         1
                                            271
                                                  3
                                                     14
                                                          18
                                                               21
                                                                 110
                                                                       59
   [16]
         51 703 123
                      101 104
                              106
                                   228 119
                                            121 146
                                                    425
                                                                  154 165
#>
                                                          55 137
#>
   [31] 415 171 407 190
                          246
                              212 142 244
                                            254
                                                 68
                                                     272 278
                                                             279
                                                                   95
                                                                       61
   [46] 572 346 1141 641
                          374 376 704 400
                                             75 413 416 1181
                                                             423 427
                                                                       89
#>
   [61] 440 798 444
                       69
                              475 839 488 622
                                                526 508 882
                                                                  551 207
#>
                           64
                                                              203
#>
   [76] 570 583
                  62 777 846 604 1574 623 625 141 1971 128
                                                             210
                                                                  645 651
   [91] 563 678 689
                      302
                           42 585 871 1520 350 1010
#>
```